

QuantImmuBench 深度分析 · 一个被忽视的评测混杂

肽长与 ELISpot 免疫原性 一个被忽视的评测混杂及其矫正

QuantImmuBench 深度分析 · DS2 Braun 2025

130 肽 / 9 患者 · 逐患者秩相关

主指标 = 肽长与 ELISpot 的 per-patient Spearman

本次分析导览

一 • 长肽为何 ELISpot 更高

存在性：逐患者森林图证据

方法：去掉肽长影响的处理与公式

稳健性：七道检验都指向同一个结论

机制：合成长肽的真实生物学

二 • 要不要矫正、怎么矫、为什么温和

差异性：单看肽长本身带来的影响因工具而异

方案菜单：多族矫正方法取舍

两层机制：工具打分是否随肽长走、以及综合方式

排名影响：去掉肽长后格局基本不变

三 • 给融合补交叉验证

挑工具带来的虚高：SURV6 从未交叉验证

补充分析：重选综合方式 / 判别 / 假满分相关审计

四 • 其他发现与结论

小样本虚高：单患者夸大原始相关的 bug

新颖性：肽长作评测混杂未见先例

建议与局限：并列报告、单队列待外验

一页看懂我们发现了什么

① 长肽 ELISpot 更高：真且稳

逐患者 $\rho^+ = +0.380$ ，七道检验都指向同一个结论；控肿瘤表达 TPM、克隆性 CCF、子肽数后仍成立。

机制是合成长肽（把突变那段做成一条较长的肽）的真实生物学，不是投料剂量假象。

② 该矫正，但影响温和

肽被合成多长是做疫苗时人为定的、不是突变本身的性质，应从评分里扣除；但多数工具的评分并不随肽长走，去掉肽长后只改动几个百分点。

把子片段打分求和这种综合方式最危险（相关 0.61），取最大值最稳。

③ 顺带修出一个小样本 bug

与肽长无关：个别工具在某患者仅三个非空值时出现虚假满相关，HLAthena 被从真实的 0.207 抬到 0.627。

按有效样本 ≥ 8 门控即修正。

④ 融合的优势主要来自挑工具的虚高

给融合补交叉验证后：几何平均整合 0.352 已不胜最强单工具 MHCnuggets 0.447；表观优势约 0.17 来自未交叉验证时挑哪几个工具带来的虚高。

头条的 SURV6 六工具无交叉验证依据。

本文用到的指标与参数（先看这页再看后面）

核心指标

逐患者 Spearman ρ^- ：在每位患者体内，把工具的预测分和实测 ELISpot 各自按大小排名，看两个排名合不合拍——+1 完全一致、0 无关、-1 相反；再把 9 位患者的值平均。这是全文主指标，越高说明工具越准。

ρ_{XZ} ：某个工具的打分和「肽长」之间的这种排名相关——用来看这个工具的分是不是跟着肽长一起变。

置信区间 (CI)：这个数的误差范围；区间不跨过 0，就说明方向可信。

p 值：纯靠运气也能出现这么大结果的概率；越小越不像是巧合。

矫正与融合里的参数

作弊上限 (oracle)：用全部数据又挑工具又打分，最乐观的数。

交叉验证 (CV)：留一部分数据不参与挑选、只拿来「考试」，反映真实水平。

挑工具的虚高 = 作弊上限 - 交叉验证。

Δ (delta)：两个数之差、或前后变化。Kendall：两个排名有多一致 (1=完全一致)。

AUPRC / AUROC：把肽分成「有免疫反应/无反应」两类时，判别好坏的两个常用分，越高越好。

数据里的量

ELISpot (SFC)：实验测到的斑点数，代表免疫反应强弱（本文的「标准答案」）。

TPM / CCF：这个突变在肿瘤里的表达量 / 克隆占比。子肽数：一条长肽里含突变的小片段个数。

综合方式 (pooling)：把一条肽内多个小片段的打分合成一个分——取最大值 max、求和 sum、几何平均 geomean、取前几高再平均 top-k 等。

为什么要把肽长（疫苗人为定的长度）从免疫原性评分里分离

第一步：先确证现象是否存在

评测里反复观察到一个现象——疫苗合成肽越长，ELISpot 检测到的免疫原性反应越强。

所以第一步要严谨确证这一「肽越长、ELISpot 越高」的关系在数据里是否真实存在、在控制其他因素后是否依然成立。

只有先站稳「存在」，后面讨论它对工具评测的影响才有意义。


第二步：它是否让工具排名虚高、需矫正

若现象存在，接着要问它是否让不同工具的排序能力被系统性抬高，从而需要在评分里把肽长的贡献扣除。

评测的真正目标，是拿到突变本身的免疫原性；而肽长只是这条肽被合成多长——做疫苗时人为定的，不是突变本身的性质。

因此有必要把肽长这一人为定的因素从工具评分里分离出来，才能公平比较各工具对突变免疫原性的排序能力。

疫苗肽越长、ELISpot 越高：控制混杂后依然成立



逐患者秩相关与稳健性

逐患者 Spearman (肽长, ELISpot) 等权平均 $\rho^- = +0.380$, 95% 置信区间从 +0.196 到 +0.558, 9 位患者中有 8 位为正。

控制肿瘤表达 TPM 与克隆性 CCF 之后仍为 +0.299, 控制子肽数之后仍为 +0.314, 两个置信区间均不含 0。

这说明长肽的高 ELISpot 并不是搭表达、克隆性或子肽计数的便车, 而是肽长本身的独立效应。

另一队列 DS1 的肽全部为 9 个氨基酸的短肽、没有长度变异, 小鼠数据又缺失, 因此当前结论基于单一队列, 仍待外部验证。

图左为各处理的相关与置信区间, 图右为九位患者各自的体内相关; 每组处理的含义与去掉肽长影响的公式见后两页。

去掉肽长影响的处理与公式

森林图每组处理的含义

主指标：每位患者体内单独算肽长与 ELISpot 的 Spearman 秩相关，再把九位患者的值用 Fisher-z 变换后等权平均，每位患者一票。

控混杂：在上面基础上，把肿瘤表达、克隆性、子肽数、插入缺失标记等因素扣掉后再算相关（即偏相关），看肽长还剩多少相关。

分层：只在错义或插入缺失、驱动或乘客等子集内分别计算，看效应是否只由某一类肽驱动。

1. 患者内秩相关

$$\rho_p = \text{corr}(R(L_p), R(E_p)), \quad R = \text{rank}$$

L 为肽长，E 为 ELISpot；先秩化再相关

2. 跨患者 Fisher-z 聚合

$$z_p = \text{arctanh}(\rho_p) = \frac{1}{2} \ln \frac{1+\rho_p}{1-\rho_p}, \quad \bar{\rho} = \tanh\left(\frac{1}{k} \sum_p z_p\right)$$

每位患者一票，等权平均

3. 偏相关（两侧扣除 Z）

$$\rho_{XY \cdot Z} = \frac{\rho_{XY} - \rho_{XZ} \rho_{YZ}}{\sqrt{(1 - \rho_{XZ}^2)(1 - \rho_{YZ}^2)}}$$

从 X-Y 相关中减去 Z 能解释的部分

4. 残差化（仅从 ELISpot 扣除长度）

$$e_Y = R(Y) - \hat{R}(Y), \quad \rho = \text{corr}(R(X), e_Y)$$

$\hat{R}(Y)$ 为 R(Y) 对 [1, R(Z)] 的最小二乘拟合

5. 多变量联控

$$e_X = R(X) - \hat{R}(X), \quad e_Y = R(Y) - \hat{R}(Y), \quad \rho = \text{corr}(e_X, e_Y)$$


两残差对 [1, R(Z₁), ..., R(Z_m)] 一并扣除

6. 置信区间与零分布

CI_{95%}: 患者 bootstrap 2000 次; p: 患者内打乱 5000 次

X = 工具评分或肽长, Y = ELISpot, Z = 混杂 (肽长 / TPM / CCF / 子肽数 / indel)

存在性稳健性：七道检验都指向同一个结论



七道检验与小结

独立复算（不用引擎重写）： $\rho^- = 0.380$ ，与原实现逐位一致。

逐患者留一：任意去掉一位患者， ρ^- 仍在 0.302 到 0.422 之间，九次全为正。

患者体内置换检验： $p = 0.0004$ 。

符号检验：九位患者八位为正，双尾 $p = 0.039$ 。

用原值（非秩）的 Pearson：0.435，比秩相关更强。


改用 8 到 11 氨基酸窗口重新计算：0.380，一致。

单项与双项控制（表达、克隆性、子肽数）后置信区间均不含零；唯有同时控制全部四个因素时点估计仍为正 0.215，但因患者仅八位、功效不足，置信区间跨零，不作为显著结论。

小结：主效应在六道检验下都指向同一个结论且置信区间不过零，唯一边界是四因素同控的小样本功效损失。

不是投料剂量假象，更可能是合成长肽的真实生物学

肽长本身显著预测 ELISpot 反应强弱 —— 肽长是需控制的混杂 (平均 $\rho \approx 0.38$, 逼近最强单工具 0.45)




为什么长肽给出更强反应

Braun 疫苗用 15 到 33 个氨基酸的合成长肽本身来刺激，配肽时按等质量投放。等质量之下，长肽的摩尔数更少、可用表位拷贝更少，本应给出更低的 ELISpot；而短肽在 ELISpot 里可以被直接负载呈递、技术上本就偏高。两条都指向长肽应更低，实测却更高。

因此这不是投料剂量造成的假象，更可能是合成长肽的真实生物学：长肽携带更多辅助性 T 细胞表位，需要经过抗原加工与交叉呈递，从而诱导更强的反应。需保留一句限定，本实验含体外扩增，长肽经辅助获得了系统性放大，属于真实免疫原性，但不等同于体内保护效力。

单看肽长本身带来的影响因工具而异、不均匀，但整体变化很小



去掉肽长前后的差异 = 单看肽长本身带来的影响

把每个工具的评分与 ELISpot 的相关，在去掉肽长前后做比较，得到的差异就是单看肽长本身带来的影响。

跨工具平均只有 +0.016，最大的是 TSCAPE 的 +0.102；有的工具被长度抬高 (TSCAPE、ImmuneApp、IEDB_Calis)，有的反而被压低 (netMHCpan-BA、NeoTImmuML)。

关键区别在于：肽长自身与 ELISpot 的相关很强 (0.38)，但一个工具要被污染，得它自己的评分也随长度走，而多数工具并非如此，所以去掉肽长对多数工具只改动几个百分点。

结论是：这一影响因工具而异、并非均匀，所以该矫正、不能当成对所有方法一致的噪音；但整体变化很小，不会天翻地覆地重排。

矫正混杂有多族标准方法：这里该用哪种


方法	原理	本场景（逐患者秩相关，患者约 9，混杂与信号共线）
偏 Spearman（主分析）	对评分与 ELISpot 各自扣除肽长后再算相关	最贴合，两边都扣肽长、小样本下方向可信
先从 ELISpot 减掉肽长（稳健性对照）	只从 ELISpot 标签扣除肽长再与评分相关	适合对照，与主分析一致即加固
分层/分箱内比较	在肽长同层内比较再合并	弱，连续肽长分箱后每层样本过少
回归调整	肽长作协变量同入回归	可补充，能同控多因素但小样本系数不稳
逆概率加权/匹配	按肽长平衡分布	不推荐，为离散处理设计、连续肽长且样本少
秩内归一	层内秩归一再合并	仅附注，同受小样本分层拖累

主张

这里样本太少（约 9 位患者），分层、加权匹配都不好用；所以主用「偏 Spearman」（扣掉肽长再算相关），另配「先从 ELISpot 减掉肽长」做对照，两个结果一致就更可信。

为什么多数工具几乎不受肽长影响

去掉肽长后的变化，取决于工具打分随肽长走的程度



来源 `mechanism_toollevel.csv · PEPTIDE_LENGTH_CONFOUNDER.md §3a`

为什么多数工具几乎不受肽长影响

肽长自身与 ELISpot 的相关约为 0.38，这个值对所有工具都一样；但肽长要经过工具才能污染它的评分，真正决定某个工具会不会被拉低的，是这个工具的打分跟不跟着肽长一起变。


由公式可推出，去掉肽长的改动量，主要由『工具打分跟肽长一起变的程度』决定（近似为 0.41 乘以它、再减去 0.08 乘以原始相关）。

数据验证：28 个工具里，『工具打分随肽长变的程度』与去掉肽长的改动量，相关达到 0.72；有 79% 的工具这一程度小于 0.2，它们平均只被去掉肽长改动 0.035。

所以「肽长自身相关很强」与「多数工具没被搅动」并不矛盾：强的是肽长跟 ELISpot 的关系，而工具被不被拉要看它自己的打分跟不跟肽长走，多数工具几乎不跟。

不同的综合方式，受肽长影响差别很大

受肽长影响的程度，取决于怎么把片段分数合成一个分



来源 mechanism_pooling.csv · 取最大值/top-k: 一条肽能选的小片段越多越易蒙到高分

不同综合方式，受肽长影响差别很大

肽越长内部子肽窗口越多（子肽数与肽长相关 0.755），长度几乎全通过「窗口数」这个通道起作用；一种综合方式越是随窗口数增多而系统抬升，就越受肽长影响。

求和最危险：它机械地正比于窗口数，跨工具平均相关高达 0.61，这正是项目弃用求和的原因。

取最大值、均值、几何均值、softmax、rankdecay 都很低，在 0.10 到 0.16 之间；项目主分析给免疫原性工具取最大值、并且不用求和，正是受肽长影响最小的一档。

中间档的 top-k 均值（k 在 3 到 20）反而比取最大值略高，因为「从更多窗口里挑出 k 个最高再平均」带来选择增益，这个增益在中等 k 最强，两头反而弱；因此项目给结合类工具用的 top-k 综合方式，是除求和外最该去掉肽长的。

去掉肽长后工具排名基本没变，几何平均融合仍最稳

工具排名基本没变

去掉肽长前后，工具排名的 Kendall 一致性约为 0.76，也就是排名基本没变、几乎不重排。

排序能力最强的几个工具——MHCnuggets、netMHCpan-BA、MHCflurry、PRIME——在去掉肽长前后都稳居前列。

换句话说，扣除肽长这一人为定的因素之后，谁强谁弱的整体格局基本不变。


融合：几何平均仍居首

几何平均在头部维度配置下、即使去掉肽长也仍是最稳的融合方式（把几个工具的打分做几何平均，不看答案、不会作弊）。

六维配置从 0.402 降至 0.330 仍居首，七维配置从 0.449 降至 0.407 仍居首。

但去掉肽长之后，它对最强单工具（netMHCpan-BA 约 0.432）的领先收窄为大致持平。

Fusion 交叉验证：整合优势主要来自挑了哪几个工具



给多工具融合补交叉验证后的发现

把几个工具打分做几何平均来综合，不看答案、不会把不该看到的信息用进去；但头条的六工具组合 SURV6，成员是在全数据上挑定、从未交叉验证，存在挑工具带来的虚高。

补一层严格交叉验证（把一位患者放到一边，只用其余患者来挑工具，再回头考这位患者）后，几何平均整合点估计 0.352 已低于最强单工具 MHCnuggets 的 0.447；配对检验 p 为 0.12 与 0.55，九位患者功效不足，未检出差异不等于两者相等。

须分清两个数：固定六工具组合几乎没被夸大，0.366 与严格交叉验证 0.352 只差约 0.01；而 0.17 是「重新挑工具」这一动作带来的虚高上限（全数据 0.525 减 0.352）。

若结合亲和力工具的授权未获批，可报告组合里整合会显著落后单工具，此时应直接部署最强单工具 MHCnuggets。

补充分析：去掉肽长后对下游的影响

把去掉肽长后的分析推到下游

把去掉肽长后的分析推到下游——最优综合方式的重选、二分类判别、机制的饱和度、以及所有综合方式的小样本假满分相关审计。

发现	结果
去掉肽长后重选最优综合方式	13/30 工具换选综合方式，工具榜 HLAthena 从第 1 跌到第 18 (0.627→0.250)
长度对二分类判别	先减掉肽长影响后 AUPRC 排名一致性 0.63，比连续排序的 0.76 更受长度影响
饱和度假说	四个饱和度量里两个方向符合、两个反向，弱支持、非干净确认
小样本假满分相关审计	从只看取最大值的 2 个，扩到全部综合方式的 95 个假满分点，小 k 与 softmax 占 44%

一个与肽长无关的小样本偏高：应独立优先修正

两个工具的原始相关被单个小样本患者夸大

核对时发现，两个工具的原始相关被单个小样本患者夸大：HLAthena 在患者 P101 上仅有 3 个非空评分，产生了虚假的完全相关，把它的相关从真实的约 0.207 抬高到 0.627；NetTepi 在患者 P102 上同理。

之前「HLAthena 因肽长掉 0.377」这一例子，大半其实来自这个小样本偏高，而非肽长。

这是独立于肽长的问题，应优先修正

这是一个与肽长无关的独立问题，不应和肽长混杂混为一谈。

项目已有的、要求每位患者有效样本不少于 8 的算法给出修正值：HLAthena 为 0.207、NetTepi 为 0.293。

建议将这一算法设为主榜，并优先修正这两个被小样本夸大的相关。

把肽长当作需统计扣除的评测混杂，检索未见先例

新颖性定位

肽长作为免疫原性特征早已进入各类模型，这一点并不新。

但把肽长当作会让工具排名虚高、需要用统计方法扣除的评测混杂，在疫苗 ELISpot 幅度评测这一具体场景里，检索未见先例。

领域的通行做法是控制 MHC 结合并做长度分布匹配，而不是用秩相关来矫正肽长这一混杂。

三条结论

其一，长肽的高 ELISpot 真实且在队列内稳健，机制是合成长肽的生物学，而非投料剂量假象。

其二，肽长对工具排名有差异但温和的影响，未校正与校正后的结果应并列报告。

其三，另有一个与肽长无关的小样本偏高问题，应优先修正。

落地建议与局限

建议

校正肽长后的结果不替换主结果，两者并列报告。

优先修正那个与肽长无关的小样本偏高问题。

可考虑把这两个发现写成一个评测严谨性的小节，作为方法学层面的贡献。

局限

本结论基于单一队列：DS1 全为 9mer 无法复现长度效应，小鼠数据缺失。

Braun 原文的精确配肽浓度经二手提取，等质量方向已由 Ott 2017 佐证，但仍建议人工核对补充材料。

融合分析目前仅做到单工具与融合层，其余留作后续工作。

正在接续跑：给融合选择补原则化交叉验证

在解决的问题

融合到底该选哪些工具、选几个、用哪种融合方式，目前没有原则化答案。

头条的六工具组合当初是在全部数据上挑定的、从没系统交叉验证过，没有可追溯的选择依据。

正在跑什么 + 状态

一套不会把不该看到的信息用进去的交叉验证选择引擎：随工具个数变化的曲线回答『选几个』、五种选择程序横比回答『怎么选』、稳定性选择回答『哪些工具可信』、两组把答案打乱后的对照，用来区分挑工具靠的是运气还是真信号。

另有十三条『每个方法学决策各配一个受控对照实验』，逐条证明为什么这样做。

要先说清的前提：九位患者下不宣称唯一最优，报交叉验证最优、加上统计上分不出高下的一批组合、加上入选频率；预期很可能是少数几个工具、甚至单个最强工具就够。

状态：引擎已建成、含零偏离自检，正在运行，约几分钟出结果。