

癌症个性化新抗原疫苗 · 工具 Benchmark

新抗原免疫原性预测工具 部署测试报告

5 个预测工具 · 部署 / 运行 / 4 类信息收集 · ELISpot 真实数据验证

汇报人 余嘉 (legacccy)

协作项目 袁老师课题组 · 西交利物浦大学

任务目标与我负责的子任务

项目总目标

做一个能预测 T 细胞免疫反应

「强弱定量程度」

的工具 —— 比现有只判「有 / 无免疫原性」的二分类更进一步。

技术路线

大量 benchmark 现有工具 + 数据集 → 结合自研 QuantImmune 算法

我的子任务：在 HPC 部署并测试运行 5 个工具，每个收集 4 类信息 → PPT

每个工具需收集的 4 类信息



输入数据的模板 / 格式

文件类型、必填列、肽长限制、HLA 格式



预测工具运行参数

可调参数的类型及功能、运行模式



输出数据格式及含义

关键列、分数类型、能否定量强弱



工具简介

方法、特点、优势与局限

5 个工具 · 部署与运行状态一览

工具	方法	能否定量强弱	本地 WSL2	HPC	端到端「肽段→分数」
DeepImmuno	CNN	✔ 连续 0-1	✔ 跑通	✔ 0.5325	✔ 完全跑通
PredIG	XGBoost	✔ 连续 0-1	✔ 跑通	✔ 0.00614	✔ 完全跑通
IMPROVE	RandomForest	✔ 连续 0-1	● Predict 步	● Predict 步	⚠ 部分 (特征链)
NeoTImmuML	集成 ML	✔ 概率	● 重训跑通	● env 就绪	⚠ 部分 (需重训)
pTuneos	ML pipeline	✔ 排名分	✔ 端到端	● sif 受限	✔ Pre&RecNeo

结论： 5 工具全部部署 / 环境就绪；其中 **5 / 5 均产出 ELISpot 真实分数并完成 benchmark**。DeepImmuno、PredIG 本地 +HPC 双验证完全端到端；pTuneos 本地 docker 端到端 (Pre&RecNeo 子模型跑 ELISpot)；IMPROVE/NeoTImmuML 部分 (缺口明确，非「装不上」)。5 个均输出连续 / 概率分数 → 都支持「强弱定量」。

「部分完成」 = 工具自身限制，非部署失败： IMPROVE 缺 ELISpot 没有的 RNA-seq 表达量 → Expression 特征降级、排序精度打折；NeoTImmuML 无官方预训练权重 → 用公开数据自训版 (不对标原论文数值)。两者均能出分、不影响进 benchmark。

DeepImmuno

✓ 完全跑通

方法: CNN

深度学习 (CNN) 预测肽段对 CD8+ T 细胞的免疫原性 (HLA-I), 附 GAN 生成功能

① 输入数据 / 格式

- CSV, 无表头两列 peptide,HLA
- 肽段长度死限 9 / 10-mer
- HLA 格式 HLA-A*0201
- 无需基因组 / HLA 库

② 运行参数

- --mode single 单条 (结果打 stdout)
- --mode multiple --intdir --outdir 批量
- 无可调超参; 须在 repo 根目录运行

③ 输出格式 / 含义

- tab 分隔 peptide / HLA / immunogenicity
- immunogenicity = 连续 0-1 (越高越强)
- 实测 NLVPMVATV(CMV)=0.957、GILGFVFTL(流感)=0.887 → 已知强表位高分, 合理

④ 简介 / 特点优势

- 最轻量, 纯肽段 +HLA 即可, 无许可工具依赖, CPU 可跑
- 部署: Python3.8 + TF2.3 + protobuf3.20 (坑: 不降报 Descriptors 错)
- 局限: 肽长死限 9/10-mer

PredIG

✓ 完全跑通

方法: XGBoost

XGBoost 预测 T 细胞表位免疫原性, 三类抗原专用模型, 可解释

① 输入数据 / 格式

- 3 模式: CSV-Uniprot / CSV-Recombinant / FASTA
- Recombinant 列 epitope,HLA_allele,protein_seq,protein_name
- 肽段 8-14 AA

② 运行参数

- --modelXG {neoant | noncan | path}
- --type {uniprot | recombinant | fasta}
- -o 输出文件

③ 输出格式 / 含义

- CSV, PredIG 列 = 连续 0-1 免疫原性分
- + NOAH / NetCleave / 物化 / TCR_contact 等 13 列特征
- 实测 SLLMWITQV = 0.0061

④ 简介 / 特点优势

- 连续分 + 可解释特征 + 容器化 (依赖全打包)
- 部署: 官方 Docker 镜像 (14.4G)→ HPC 转 Singularity (predig.sif 4.6G)
- 局限: 镜像大

IMPROVE

 部分完成

方法: RandomForest

随机森林预测新表位免疫原性, 22 特征, 三变体 (Simple / TME_excluded / TME_included)

① 输入数据 / 格式

- TSV, 必填 突变肽 + 野生型肽 + HLA
- 肽段 8-12 AA
- 两步流程: ① feature_calc 算特征 ② Predict 跑 RF

② 运行参数

- 步 2 --model {Simple | TME_excluded | TME_included}
- 每变体加载 5 个 RF (rf0-rf4 集成)

③ 输出格式 / 含义

- TSV 追加 mean_prediction_rf (连续 0-1)
- = 5fold × 50 RF 集成平均
- 实测 Simple 变体 EEFLNSWML = 0.5146

④ 简介 / 特点优势

- RF 22 特征, 专为新表位排名设计, 整合 TCR 识别 (PRIME)
- ⚠ 数据缺口: ELISpot 仅肽 +HLA, 无 RNA-seq → Expression / NetMHCExp 必 impute; Stability 可经容器补
- Predict 步本地 +HPC 跑通; 许可工具 (netMHCpan/PRIME) 已到位, 全特征链余 netMHCstabpan(glibc 挡)+self_similarity/garnish 待补

NeoTimmuML

⚠ 部分 (已重训)

方法：集成 ML

加权集成 (LightGBM+XGBoost+RandomForest) 预测肿瘤新抗原免疫原性, 78 个肽段物化特征

① 输入数据 / 格式

- CSV: Peptide + immunogenicity(标签) + 78 个 R Peptides 物化特征
- 肽段 8-13 AA, 不要 HLA
- 78 特征须先用 R Peptides 包外部算好

② 运行参数

- 不是 CLI, 是 Jupyter notebook (21 cell)
- 改 file_path 指数据; 内含 8 算法对比 + 加权集成 + 5fold CV

③ 输出格式 / 含义

- 分类指标 + 雷达图 + predict_proba 连续概率
- → 能定量强弱
- 自训后 10536 ELISpot 肽出分 0.0002-0.9974

④ 简介 / 特点优势

- 纯肽特征, 不要 HLA / 不要 netMHCpan 等许可工具 (部署最轻)
- 局限: 研究 notebook 无预训练权重 → 用 TumorAgDB2.0 (36535 行) 重训
- 不含 78 特征计算代码 → 须 R Peptides 算

pTuneos

 端到端跑通

方法：ML pipeline

个性化新抗原全流程 pipeline (WES/RNA-seq 或 VCF → 排名)；识别子模型可单独跑肽段

① 输入数据 / 格式

- 完整 pipeline：VCF + 表达谱 + 拷贝数 + 纯度 + HLA (需全基因组, 吃不了纯肽)
- ★ Pre&RecNeo 子模型：仅 MT_pep + WT_pep + HLA 三列 (可跑 ELISpot 肽)

② 运行参数

- 完整：python pTuneos.py {WES|VCF} -i config.yaml
- Pre&RecNeo：自写 wrapper 调 InVivoModelAndScore
- 批 netMHCpan/blastp 加速 + nproc 并行

③ 输出格式 / 含义

- RefinedNeo = 患者级排名分 (乘表达 / VAF / 克隆性, 需测序)
- Pre&RecNeo (model_pro) = 纯肽免疫原性识别分 → 与其他 4 工具可比
- example VCF 出 40 新抗原 (RefinedNeo 0.42–1.13)

④ 简介 / 特点优势

- 镜像自带 netMHCpan-4.0 / VEP / GATK / BWA 全套；修 8 坑 + VEP cache 14G 端到端跑通
- Pre&RecNeo 跑 ELISpot 32178 肽对 → 进 5 工具 benchmark (对账官方 $r=1.0$)
- ⚠ 诚实：本地 docker 跑 (HPC sif 受限 singularity 非 root)；疏水模型仅 9/10/11mer

部署环境与关键技术问题

部署环境

本机 WSL2 Ubuntu 24.04

调试主战场 · GPU 直通 RTX4070 · conda + Docker

XJTLU HPC

dtn.hpc.xjtlu.edu.cn · 最终部署目标

Singularity 3.11.3 + module miniconda3 + gpfs 136T

上网

github / pypi / DTU  Docker Hub 

关键技术问题与解决（踩坑）

Windows 跑不动

repo 含非法 * 文件名 → NTFS checkout 崩
→ 全转 WSL2/HPC Linux

版本地狱

老 TF/numpy/protobuf → 严格按官方 pin
建独立 conda env

Docker Hub 国内不通

WSL mirrored 网络 + daemon 代理拉镜像;
HPC 转 Singularity

2014 老二进制 segfault

WSL 内核 vsyscall → .wslconfig 加
vsyscall=emulate

HPC glibc 2.28 < 2.29

netMHCstabpan 二进制原生跑不了 → 需新
glibc 容器

git-lfs 大文件

models 1.9G : --depth 1 只得指针 → git lfs
pull


用袁老师 ELISpot 真实数据跑通

数据处理管线


DS1 (83 行全 9-mer) 直接喂；DS2 (101 行变长) 滑窗截取 8-14mer。HLA 归一后按各工具格式生成输入，输出回贴主干表 (34247 行)。

DeepImmuno	17,103 行
PredIG	68,494 行
IMPROVE	26,790 行
NeoTImmuML	10,536 行
pTuneos	34,247 行


5 / 5 工具产出 ELISpot 真实免疫原性分数 (pTuneos 用 Pre&RecNeo 子模型跑肽段, 对账官方 $r=1.0$)



阈值敏感性 · 定量相关 · 官方 / 改动透明



① 阈值敏感: pTuneos >0 最高 (0.78), 但 >10/>median 跌到 0.51/0.46 = 门槛效应; PredIG/IMPROVE 跨阈值稳



② 定量相关 (分数 vs ELISpot SFU): PredIG $p=0.28^{**}$ / IMPROVE $p=0.21^{*}$ 能跟踪强度; pTuneos $p=0.03$ (ns) 不跟踪

✅ 完全官方 (算法 / 分数没动)

5 工具模型 / 权重 / 评分; pTuneos model_pro 数值 ($r=1.0$ 对账证); netMHCpan/blastp/VEP 等外部工具

🔧 我们的改动 (需标清)

ELISpot 滑窗 / 格式转换 · benchmark 评估框架 + 所有图 · Δ pTuneos 喂肽段 (抠识别子模型, 合法但非官方标准流程) · 批处理加速 (结果同) · 修部署 8 坑 (不改算法)

结论与下一步

已达成

- 5 工具全部部署 / 环境就绪
- 2 个完全端到端跑通 (DeepImmuno、PredIG), 本地 +HPC 双验证
- 5 / 5 产出 ELISpot 真实分数 + benchmark (pTuneos 用 Pre&RecNeo 子模型, pTuneos AUC 最高 0.75)
- 4 类信息全部收集完成 (逐工具文档齐)

剩余缺口 (诚实标注)

IMPROVE 全特征链

Expression/NetMHCExp 需 RNA-seq, ELISpot 无 → 结构性 impute

NeoTImmuML 权重

研究 notebook 无预训练权重, 已用公开库自训补

pTuneos HPC 真跑

本地 docker 已端到端; HPC singularity 非 root/fakeroor 受限, 待重打包

袁老师正式数据

到位后按各工具格式做转换 → 正式测试