

癌症个性化新抗原疫苗 · 预测工具部署与基准评估

新抗原免疫原性预测工具 部署测试与基准评估报告

第一批 5 工具: DeepImmuno · PredIG · pTuneos · IMPROVE · NeoTImmuML

内容 逐工具部署 + 工作原理 + 四类信息 · ELISpot 统一基准评估
项目 癌症新抗原疫苗协作项目

本报告的内容结构

01

项目背景与任务

要解决什么、本报告做了什么

02

工具逐一解析

每个工具的工作原理 + 四类信息

03

部署工程与踩坑

环境、典型问题与解决（按工具归属）

04

数据与评测方法

测试数据来源、评测流程、指标说明

05

基准结果

判别力 / 能否定量 / 工具间一致性

06

诚实边界与许可

已知限制、口径、许可红线

07

结论与下一步

总结与后续计划

目标 · 报告范围 · 四类信息

项目目标

构建一个能预测 T 细胞反应「**强弱程度**」的工具。
现有工具多数只判断「是否具有免疫原性」（二分类）；目标是更进一步，给出反应强度的连续估计（定量）。

本报告范围

对第一批 5 个现有免疫原性预测工具完成部署与运行测试，
在统一的 ELISpot 实验数据上做横向基准评估，
每个工具记录 4 类信息并整理成本报告。

每个工具记录的 4 类信息



输入数据格式

文件格式、必填列、肽段长度、HLA 写法



运行参数

可调参数及其功能、运行模式



输出数据含义

关键列、分数类型、能否定量强弱



工具简介

所用方法、特点、优势与限制

5 个工具均完成部署并产出可进入基准的连续分数；端到端完整度分级见下页。

5 个工具：方法 · 端到端完整度 · 基准判别力

工具	方法	能否定量	基准 AUC*	端到端完整度
DeepImmuno	卷积网络 CNN	连续 0-1	0.481	完整端到端
PredIG	梯度提升树	连续 0-1	0.661	完整端到端
pTuneos	机器学习流程	排名分	0.752	子模型 (对账 r=1.0)
IMPROVE	随机森林	连续 0-1	0.621	特征降级
NeoTImmuML ★	集成机器学习	概率	0.655	自训版 (非官方权重)

* 基准 AUC = ELISpot 测试集 DS2、max 聚合、阈值>0 口径下的判别力 (0.5=随机, 与全项目其它交付同口径) 。完整数字见 [analysis/metrics_ds2.csv](#)。
★ NeoTImmuML：官方未发布预训练权重，基准使用基于公开数据自训的版本，数值不对标原论文。「端到端完整度」三档：完整双验证 / 子模型 / 降级或自训，均不影响进入基准，仅口径需说明。

DeepImmuno

用卷积神经网络判断一条肽段能不能激活 CD8+ T 细胞

① 用什么输入

只要两样东西：一条肽段序列（9 或 10 个氨基酸）和它对应的 HLA 分型。不需要基因组、不需要表达量，是十个工具里最省事的。

② 模型怎么算

先把氨基酸序列和 HLA 假基序按物化性质编码成一张数字矩阵，再用卷积神经网络（CNN）像扫图像一样扫过这张矩阵，自动抓出和免疫原性有关的局部模式，最后汇总成一个分数。

③ 给出什么输出

输出一个 0 到 1 之间的连续分，越接近 1 表示越可能激活 T 细胞。实测已知强表位（如 CMV 的 NLVPMVATV）确实拿到高分，符合预期。

运行命令

```
# 单条
python deepimmuno-cnn.py \
  --mode single \
  --epitope NLVPMVATV --hla HLA-A*0201
# 批量
#   --mode multiple --intdir IN --outdir OUT
```

输入数据样例

```
# CSV, 两列, 无表头
# 肽段, HLA
NLVPMVATV,HLA-A*0201
GILGFVFTL,HLA-A*0201
```

输出数据样例

peptide	HLA	immunogenicity
NLVPMVATV	HLA-A*0201	0.957
GILGFVFTL	HLA-A*0201	0.887

DeeplImmuno

✓ 完整端到端

方法 卷积网络 CNN

用卷积神经网络判断一条肽段能否激活 CD8+ T 细胞 (HLA-I) , 最轻量、只要肽段+HLA

① 输入数据 / 格式

- CSV, 两列无表头 peptide, HLA
- 肽段长度固定 9 或 10
- HLA 写法 HLA-A*0201
- 不需要基因组 / HLA 库

② 运行参数

- --mode single 单条, 结果打印屏幕
- --mode multiple 批量, 指定输入输出目录
- 没有可调超参; 须在 repo 根目录运行

③ 输出格式 / 含义

- 三列 peptide / HLA / immunogenicity
- immunogenicity = 0~1 连续分, 越高越强
- 实测已知强表位高分 (CMV NLVPMVATV=0.957) → 合理

④ 简介 / 特点优势

- 最省事: 纯肽段+HLA 就能跑, 不依赖任何收费工具, CPU 即可
- 环境: Python3.8 + TensorFlow2.3 (protobuf 须降到 3.20)
- 限制: 肽长只能 9 或 10

PredIG

用梯度提升树预测免疫原性，并给出一串可解释的特征

① 用什么输入

输入肽段、HLA 分型，以及（重组模式下）肽段所在的蛋白序列。支持三种输入模式，肽段长度 8–14。

② 模型怎么算

先调用一串内置工具算出 13 类特征——蛋白酶切位点、提呈分（NOAH）、物化性质、TCR 接触位点等——再把这些特征喂给 XGBoost 梯度提升树模型综合打分。特征可解释是它的卖点。

③ 给出什么输出

输出一个 0 到 1 的免疫原性分（PredIG 列），同时附上那 13 列特征，方便回看模型是凭什么给的分。

运行命令

```
python predig.py \  
  --type recombinant \  
  --modelXG neoant \  
  -i input.csv \  
  -o result.csv
```

输入数据样例

```
# CSV, 重组模式  
epitope,HLA_allele,protein_seq,protein_name  
SLLMWITQV,HLA-A*0201,MSLL...,TP53
```

输出数据样例

```
# CSV, 含 PredIG 分 + 13 列特征  
epitope    PredIG    NOAH    TCR_contact  
SLLMWITQV  0.0061    0.42    ...
```

PredIG

✓ 完整端到端

方法 梯度提升树 XGBoost

用梯度提升树预测 T 细胞表位免疫原性，按抗原类型分专用模型，结果可解释

① 输入数据 / 格式

- 3 种模式: Uniprot / Recombinant / FASTA
- Recombinant 列 epitope, HLA_allele, protein_seq, protein_name
- 肽段 8–14 个氨基酸

② 运行参数

- --modelXG 选模型 (neoant / noncan / 自定义)
- --type 选输入模式
- -o 输出文件

③ 输出格式 / 含义

- CSV, PredIG 列 = 0~1 连续免疫原性分
- 另附 13 列特征 (切割/提呈/物化/TCR 接触等)
- 实测 SLLMWITQV = 0.0061

④ 简介 / 特点优势

- 连续分 + 可解释特征 + 容器化 (依赖全打包, 省去装环境)
- 环境: 官方 Docker (14.4G) → HPC 转 Singularity (4.6G)
- 限制: 镜像体积大

pTuneos

—整套新抗原流程；其中识别子模型可单独给肽段打分

① 用什么输入

完整流程要测序变异（VCF）、表达量、拷贝数、肿瘤纯度、HLA——需要全基因组数据，喂不了纯肽段。但它的识别子模型 Pre&RecNeo 只要三列：突变肽、对应野生肽、HLA，这部分能用来跑 ELISpot 肽段。

② 模型怎么算

完整流程先把测序变异注释成突变肽，再逐层打分；识别子模型则针对一对「突变肽 vs 野生肽」算结合、相似度、被 T 细胞识别等特征，输出免疫识别分。本基准用的就是这个子模型。

③ 给出什么输出

完整流程给患者级排名分（乘了表达量和突变频率，需测序）；子模型给纯肽免疫识别分，这部分可与其它工具横比。实测示例数据端到端跑出 40 个候选新抗原。

运行命令

```
# 完整流程
python pTuneos.py VCF -i config.yaml
# 识别子模型（喂肽段）
# 自写脚本调用 InVivoModelAndScore
```

输入数据样例

```
# 子模型输入：三列
MT_pep,      WT_pep,      HLA
AAAVFKTLP,   AAAVFKTLR,   HLA-A*02:01
```

输出数据样例

```
# 子模型识别分 model_pro
MT_pep      model_pro
AAAVFKTLP   0.73
```

pTuneos

⚠ 子模型端到端

方法 机器学习流程

—整套个性化新抗原流程（从测序数据到排名）；识别子模型可单独拿肽段来打分

① 输入数据 / 格式

- 完整流程：测序变异 + 表达量 + 拷贝数 + 纯度 + HLA（要全基因组，喂不了纯肽）
- ★ 识别子模型：只要 突变肽 + 野生肽 + HLA 三列（能跑 ELISpot 肽）

② 运行参数

- 完整：python pTuneos.py + 配置文件
- 子模型：自写脚本调用识别打分函数
- 可并行加速（多进程 + 批量结合预测）

③ 输出格式 / 含义

- 完整流程出患者级排名分（乘了表达/突变频率，需测序）
- 子模型出纯肽免疫原性识别分 → 这部分进基准、可与其它工具比
- 示例数据跑出 40 个候选新抗原

④ 简介 / 特点优势

- 镜像自带 netMHCpan / VEP / GATK 等全套；修了 8 处坑 + 14G 注释缓存才端到端跑通
- 进基准用的是识别子模型，对账官方逻辑一致 ($r=1.0$)，不等于整条流程的端到端能力
- 完整流程在本地容器跑通；HPC 因权限限制未跑

IMPROVE

用随机森林给新表位打分，整合了 22 个特征

① 用什么输入

输入突变肽、对应野生肽、HLA (TSV 格式，肽段 8–12)。流程分两步：先算特征，再预测。

② 模型怎么算

第一步用外部工具算出 22 个特征（包含结合、稳定性、TCR 识别 PRIME 分、自相似度等）；第二步把特征喂给随机森林（每个变体 5 个森林做集成）综合打分。本基准里表达相关特征因 ELISpot 无 RNA 数据而降级。

③ 给出什么输出

在输入表后追加一列 mean_prediction_rf，是多折多森林的集成平均分（0 到 1）。

运行命令

```
# 第一步：算特征
bash run_feature_calc.sh input.tsv
# 第二步：预测
python Predict.py --model Simple
```

输入数据样例

```
# TSV: 突变肽 + 野生肽 + HLA
Mut_pep      Norm_pep      HLA
EEFLNSWML    EEFLNSWMV    HLA-B*08:01
```

输出数据样例

```
# 追加 mean_prediction_rf 列
Mut_pep      mean_prediction_rf
EEFLNSWML    0.5146
```

IMPROVE

⚠ 特征降级

方法 随机森林

用随机森林给新表位的免疫原性打分，22 个特征，分三种变体模型

① 输入数据 / 格式

- TSV, 必填 突变肽 + 野生肽 + HLA
- 肽段 8-12 个氨基酸
- 两步走：先算特征，再跑随机森林预测

② 运行参数

- --model 选 Simple / TME_excluded / TME_included
- 每个变体加载 5 个森林做集成

③ 输出格式 / 含义

- TSV 追加一列 mean_prediction_rf (0~1 连续)
- = 多折 × 多森林的集成平均
- 实测 Simple 变体 EEFLNSWML = 0.5146

④ 简介 / 特点优势

- 22 个特征专为新表位排名设计，整合了 TCR 识别信号
- 缺口：ELISpot 没有 RNA 表达量 → 表达相关特征降级；稳定性特征依赖的外部工具受系统库版本所限
- 预测步本地+HPC 都跑通；这是「数据缺一块」不是「装不上」

NeoTImmuML ★ 自训版

三种模型加权集成，用 78 个肽段物化特征；官方无权重，本基准为自训版

① 用什么输入

输入肽段加上 78 个物化特征（要先用 R 的 Peptides 包算好），不需要 HLA，肽段 8–13。

② 模型怎么算

把 78 维特征喂给 LightGBM、XGBoost、随机森林三个模型，再加权集成成一个概率。官方仓库是研究用 notebook、没带预训练权重，所以本基准用公开肿瘤抗原库自己重训了一版（数值不对标原论文）。

③ 给出什么输出

输出 0 到 1 的免疫原性概率（predict_proba），能用来排强弱；同时给分类指标和雷达图。

运行命令

```
# 不是命令行，是 Jupyter notebook
# 改 file_path 指向数据后
# 顺序运行 21 个单元格
# （含 8 算法对比 + 加权集成）
```

输入数据样例

```
# CSV: 肽段 + 标签 + 78 特征
Peptide    label  feat1  feat2 ... feat78
AAAVFKTLP  1      0.12  -0.4  ...
```

输出数据样例

```
# predict_proba 连续概率
Peptide    immuno_prob
AAAVFKTLP  0.81
```

NeoTImmuML ★ 自训版

⚠ 自训版

方法 集成机器学习

三种模型加权集成 (LightGBM+XGBoost+随机森林) 预测肿瘤新抗原免疫原性, 用 78 个肽段物化特征

① 输入数据 / 格式

- CSV: 肽段 + 标签 + 78 个物化特征
- 肽段 8-13 个氨基酸, 不需要 HLA
- 78 个特征要先用 R 的 Peptides 包算好

② 运行参数

- 不是命令行, 是 Jupyter notebook (21 个单元格)
- 改路径指向数据; 内含 8 种算法对比 + 加权集成 + 交叉验证

③ 输出格式 / 含义

- 分类指标 + 雷达图 + 连续概率 (能分强弱)
- ★ 官方没放预训练权重 → 基准用自训的版本
- 数值不对标原论文精度

④ 简介 / 特点优势

- 纯肽段特征, 不要 HLA、不要任何收费工具, 装起来最省心
- 限制: 是研究用 notebook, 没带权重 → 用公开肿瘤抗原库重训了一版
- 不含 78 特征的计算代码 → 要自己用 R 算

两套部署战场：本机调试 + HPC 正式跑

本批 5 个工具均经两套环境：本机 WSL2 逐个调通并摸清四类信息，HPC 集群作为最终部署目标。两边出网均受限，工具多为老链需逐个适配。

本机 • WSL2 Ubuntu 24.04

- 角色：调试主场——逐个工具跑通、摸清四类信息
- 环境：直通显卡 + conda + Docker
- 为什么不用 Windows：仓库含带 * 的非法文件名，且工具多为 Linux 老链

HPC • 学校集群

- 角色：正式大规模跑 + 团队最终交付目标
- 环境：Singularity 容器（无 Docker）+ 多核 CPU
- 推理多为 CPU（梯度提升树 / 随机森林 / CNN 推理），基本不占显卡

两边共同约束

- 出网：GitHub / PyPI / DTU 通；Docker Hub 两边都不通
- 对策：本机打包镜像 → 上传 → 转 Singularity
- 学术工具（netMHCpan 等）禁止再分发，含其跑出的数字

下面先看各工具的运行环境与依赖包，再按工具逐个列出遇到的问题（标来源环境）。

各工具的运行环境与依赖包

工具	运行环境	关键包 / 版本	外部工具 / 权重
DeeplImmuno	conda · Python 3.8	tensorflow 2.3.0 · numpy 1.18.5 · pandas 1.1.1 · protobuf 3.20.3	无 (纯肽段 + HLA)
PredIG	Docker / Singularity 镜像	镜像内置 R + XGBoost 全套	NetCleave · NOAH · netCTLpan · MHCflurry (镜像自带)
pTuneos	Docker 镜像 · Python 2.7	Python 2.7 · R 3.2.3 · scikit-learn (容器内)	netMHCpan-4.0 · VEP+cache 14G · GATK · PyClone (镜像自带)
IMPROVE	conda · Python 3.11	numpy ≥2.0 · scikit-learn 1.9 · pandas · seaborn	netMHCpan-4.1 · netMHCstabpan · PRIME · MixMHCpred + models.zip 1.9G(git-lfs)
NeoTImmuML ★	conda · Python 3.10 + R	lightgbm · xgboost · scikit-learn · pandas · numpy + R Peptides 2.4.6	无外部许可工具; 权重自训 (官方未发布)

环境分两类：轻量工具用 conda 建独立 Python 环境装包；老链 / 多依赖工具用官方 Docker 镜像（HPC 转 Singularity）打包整套环境。
★ NeoTImmuML 官方未发布权重，用公开数据自训替代。学术工具（netMHCpan 等）需 DTU 许可，禁再分发。

各工具遇到的问题与解法（按工具 / 标来源）

来源标签: 本机 = 本地 WSL2 HPC = 学校集群

DeepImmuno

CNN · 本机+HPC 均通

本机 仓库含 * 文件名, Windows 存不了 → 搬 WSL2

本机 protobuf 须降 3.20; TF2.3 / Py3.8 严格对版本

HPC 顺利跑通, 结果与本机一字不差

pTuneos

Py2.7 流水线

本机 自带样例连修 8 处 bug 才端到端跑通

本机 VEP 注释库 14G 龟速 → 多连接下载提速约 12×

本机 完整版喂不了 ELISpot → 用 Pre&RecNeo 子模型进基准

HPC 镜像程序在 /root + 无 fakeroot → 改本机容器验证

NeoTImmuML ★

集成 ML · 自训替代

本机 源码 URL 未公开 → 浏览器自动化从数据库站抓出

本机 无官方权重 → 公开数据自训 (已确认全网无权重)

本机 78 特征 R 库接口随版本变 → 逐列核对修对 76/78

PredIG

XGBoost · 官方镜像

本机 镜像 14.4G + Docker Hub 墙 → mirrored + 代理 + 删旧源

本机 单次输入硬限 <5000 行 → 切块串跑再按序拼

HPC 镜像转 Singularity; 只读容器写 tmp 需 writable-tmpfs

IMPROVE

随机森林

本机 模型用新版 numpy 存 → 换 Py3.11 才读得了

本机 老二进制 netMHCpan-2.8 崩 → 内核 vsyscall 救活

本机 表达量特征需 RNA-seq, ELISpot 没有 → 该特征降级

HPC glibc 2.28 < stabpan 要 2.29 → 稳定性特征跑不了

ELISpot 实测数据 · 规模 · 正负比

DS2 · 主测试集（有阴有阳）

- 101 条肽段：有反应 90 条 / 无反应 11 条
- 来自 9 位患者；反应值 SFC 范围 -34 ~ 209
- 用途：算 AUC（能不能分开「有/无反应」）

DS1 · 定量验证集（全阳）

- 82 条肽段：全部有反应，无阴性
- 来自 6 位患者；强度 SFC 16 ~ 677（约 40 倍跨度）
- 用途：检验「能不能把强弱排对」

关键说明

标签 = ELISpot SFC

SFC = 斑点形成细胞数，T 细胞反应强度的实验读数；阈值 >0 记为有反应。

展开规模

每条肽按子肽×HLA 窗口展开，DS1+DS2 共 34,247 行预测。

局限

样本来自有限患者 → 存在聚集；DS2 阴性仅 11 条，置信区间偏宽。

数据来源：课题组 ELISpot 实测 (Elispot_Dataset1.xlsx / Elispot_Dataset2.xlsx)。

从一条肽段到工具横向对比



读这张图

同一批肽段喂给 5 个工具 → 每个工具独立打分 → 因一条肽会拆成多个子肽×HLA，统一「逐肽取最大分」聚合 → 按实验反应值 $SFC > 0$ 切「有/无反应」标签 → 用同一套指标评估 → 5 个工具在完全相同的口径下横向对比。

关键：所有工具走完全一致的聚合、阈值、指标口径，保证「apples-to-apples」可比。

用什么数据、怎么比、看什么指标

测试数据

真实 ELISpot 实验数据 DS2：101 条肽段。按实验反应值切分 —— 有反应 90 条、无反应 11 条（反应值 ≤ 0 算真无反应）。

参评工具

第一批 5 个免疫原性工具：DeepImmuno / PredIG / pTuneos / IMPROVE / NeoTImmuML。

怎么比

一条肽段拆成多个子肽 $\times$ HLA，先聚合（统一取 max 最大值，与全项目其它交付同口径）再按阈值切，保证可比。

看什么

AUC（能否分开「有反应/无反应」，0.5=随机）、AUPRC、Spearman 相关（分数与反应强弱是否同向 = 能否定量）。

后面每个数字是什么意思、最该信哪个

AUC (判别力)

★ 主看

随便挑「一条有反应 + 一条没反应」，模型给有反应那条打分更高的概率。
1=完美，0.5=和瞎猜一样，<0.5=反着的。本报告最主要看它。

Spearman 相关 (能否分强弱)

★ 看定量

模型分数的高低排序，和真实反应强弱的排序，吻合到什么程度。
+1=完全同向，0=没关系，-1=完全反着。这是「能不能分强弱」的关键。

AUPRC

参考有限

精确率-召回率曲线下的面积，阳性很少时比 AUC 更敏感。
⚠ 本数据阳性本就占 89%，起点就高 → 提升空间小，参考意义有限。


95% 置信区间 / p 值

看可信度

重复抽样 2000 次看指标的波动范围； $p < 0.05$ 才算「不是偶然」。
区间越宽=越不确定。本数据样本小（101 条、阴性仅 11）→ 区间普遍偏宽。

一句话：本报告主看 AUC（判别力）和 Spearman（能否分强弱）；AUPRC 因阳性占比高、参考有限；样本量小 → 所有指标的置信区间都偏宽，结论以「方向性」为主、不抠零点几的差距。

5 工具 AUC: 除 pTuneos / PredIG 外, 多数接近随机



两个居前

pTuneos (0.75) 与 PredIG (0.66) 在阈值>0 下判别力点估相对最好; 其余三个在 0.48–0.66 之间。

阈值敏感

换更严的阈值 (>median), pTuneos 从 0.75 掉到 0.53、DeepImmuno 始终 ≤ 0.52 → 多数工具的优势不跨阈值稳健。

样本小须谨慎

无反应样本仅 11 个, 工具间的差距置信区间较宽; 本页给点估, 不下「最优」判断。

图: 5 工具 AUC (DS2, max 聚合, 阈值>0) + 95% bootstrap CI。虚线=随机 0.5。pTuneos 0.75、PredIG 0.66 居前; DeepImmuno 0.48 低于随机。

5 工具 ROC: 多数贴近随机对角线




图: 5 工具 ROC 曲线 (DS2, max 聚合, 阈值>0)。曲线越往左上凸=判别力越强; 贴近对角线=接近随机。

怎么看

曲线离左上角越远 = 判别力越强; 贴着对角线 = 与随机猜测相当。


表现

pTuneos、PredIG 的曲线较明显凸向左上; DeepImmuno 等缠绕在对角线附近。

与柱状图一致

与上一页 AUC 柱状图相互印证: 仅少数工具具备一定判别力。

分数与真实反应强度的相关：仅个别工具显著



Spearman 相关 (分数 vs 反应强度)


IMPROVE $\rho=0.243$ ($p=0.014$, 显著)
PredIG $\rho=0.198$ ($p=0.047$, 显著)
pTuneos $\rho=0.136$ 、NeoTImmuML $\rho=0.022$ 、DeepImmuno $\rho=-0.117$ —— 均不显著。

用全阳数据 DS1 进一步验证

DS1 = 82 条肽，全部有反应（强度差约 40 倍）。在 DS2 上头部还能正向排强弱的工具，到全阳的 DS1 上相关系数普遍落到 0 附近。
说明现有工具的能力集中在「区分有/无反应」，对「反应有多强」的定量预测仍弱 —— 这正是「强弱定量」方向的空白所在。

图：5 工具 Spearman 相关 (max 聚合, 分数 vs 反应强度)。* = $p < 0.05$ 。仅 IMPROVE / PredIG 显著正相关。

把同一批肽段的打分两两比对：彼此基本不相关



大多互不相关

对角线之外多数格子接近 0 —— 不同工具对同一条肽段给的排序基本各说各话。

少数偏高

IMPROVE-pTuneos 0.31、IMPROVE-PredIG 0.28 略高，可能因方法或训练数据有重叠。

这说明什么

工具之间缺乏共识 → 没有一个是公认标准；简单做平均集成提升也有限。

图：5 工具在同一批肽段 (DS2, n=101) 上打分的两两 Spearman 相关。颜色越红越正相关，越白越不相关；对角线为自身=1

已知限制与口径说明

样本量较小

无反应样本仅 11 个 → AUC/相关的置信区间偏宽，工具间小于 0.05 的 AUC 差距不具显著性。

数据存在聚集

101 条肽来自 9 个病人，部分病人贡献较多阴性肽 → 有效样本数小于 101，判别力可能部分反映「区分病人」。

完整度分级

DeepImmuno / PredIG 完整端到端双验证；pTuneos 为识别子模型（对账 $r=1.0$ ）；IMPROVE 特征链降级；NeoTimmuML 为自训版（非官方权重）。结论按此口径解读。

聚合口径

本报告统一采用 max 聚合（与全项目其它交付一致）；换 mean / top3mean 点估略有差异，但「多数工具判别力偏弱、定量相关弱」的总体结论一致。

⚠ 许可提示

netMHCpan / netMHCstabpan

为 DTU 学术许可。未经书面同意，不得向第三方发布在其软件上跑出的结果（含数字）。

pTuneos / IMPROVE 依赖上述工具

→ 对外报告含相关对比数字前，需先取得 DTU 书面同意（投稿阶段处理）。

5 个工具的论文出处与代码仓库

工具	发表期刊 / 年份	DOI (可点击)	代码仓库 (可点击)
DeepImmuno	Briefings in Bioinformatics 2021	10.1093/bib/bbab160	github.com/frankligy/DeepImmuno
PredIG	Genome Medicine 2025	10.1186/s13073-025-01569-8	github.com/BSC-CNS-EAPM/PredIG
pTuneos	Genome Medicine 2019	10.1186/s13073-019-0679-x	github.com/bm2-lab/pTuneos
IMPROVE	Frontiers in Immunology 2024	10.3389/fimmu.2024.1360281	github.com/SRHgroup/IMPROVE_tool
NeoTImmuML	Frontiers in Immunology 2025	10.3389/fimmu.2025.1681396	github.com/01SYan19/NeoTImmuML

外部依赖工具: *netMHCpan / netMHCstabpan* (DTU Health Tech, 学术许可) · *MixMHCpred* (Gfeller lab) · *Ensembl VEP* · *R Peptides* 包。

结论与下一步

已完成

- 5 个工具全部完成部署，四类信息逐工具记录齐全
- DeepImmuno / PredIG 完整端到端双验证；其余按口径诚实分级
- ELISpot 基准结论：5 个工具判别力总体偏弱，仅 pTuneos / PredIG 点估居前；定量相关仅 IMPROVE / PredIG 显著
- 现有工具对「反应强弱」的定量预测仍弱 → 该方向存在明确空白与价值

下一步

扩充阴性样本

无反应样本仅 11 个 → 补充至 ≥ 30 后重测，使结论更稳

统一多聚合口径

补充 max / top3mean 口径的对照，确认结论稳健

核连续标签数据量

评估公开库中带反应强度标签的数据是否足以支撑定量回归

接入正式数据

正式数据到位后按各工具格式转换并正式测试

对外许可

对外报告含 netMHCpan 相关数字前取 DTU 书面同意